


一、不同领域的AI算法00:00

1. 课前学习目标 04:08

1) 课前学习目标介绍



- 学习重点：掌握金融、制造、快消三大领域的AI算法应用
- 实践目标：通过特征工程优化二手车价格预测模型，降低MAE指标
- 行业应用：重点讲解金融行业的7个应用场景（个人金融、公司金融等）

2) 算法选择依据 06:14

- 任务导向：
 - 分类任务：常用决策树、随机森林、逻辑回归
 - 回归任务：神经网络具有较强适应性
- 模型特性：
 - 可解释性：决策树、逻辑回归更优
 - 防过拟合：随机森林表现良好
 - 通用性：神经网络适合多种场景

3) 提交成绩要求 06:48

- 截止时间：课程结束时统一提交
- 提交内容：需包含个人ID、姓名和最终成绩
- 成绩标准：二手车价格预测MAE需小于500分
- 尝试次数：每天5次提交机会（次日重置）

4) 工具使用问题答疑 07:36

- 常见问题：
 - 格式错误：确认使用.csv格式文件
 - 训练中断：按ESC键多次可强制终止
 - 粘贴异常：可先保存到.txt文件再导入
- 版本管理：
 - 建议定期备份代码版本
 - 部分工具（如Coser）支持版本回退

5) 模型调优方法 09:13

- 核心原则：特征工程决定模型上限
- 具体方法：
 - 特征优化：挖掘有效特征组合
 - 模型选择：使用抗过拟合模型（如XGBoost）
 - 训练策略：适当增加训练轮数（可设10000轮）
- 避免误区：网格搜索耗时但效果有限

6) 本地验证方法 10:05

- 验证集构建：


- 划分小规模数据 (20-30%)
 - 保持与测试集同分布
 - **验证技巧:**
 - 本地测试通过后再提交
 - 可减少每日提交次数浪费
 - **注意事项:** 验证集不可参与训练
- 7) 工具更新与问题解决 11:49
- **更新方法:**
 - 命令行执行: `npm update package-name`
 - 建议定期检查更新
 - **故障处理:**
 - 网络问题优先切换国内节点
 - 复杂问题可联系技术支持
- 8) 笔记本电脑使用与成绩标准 12:43
- **硬件要求:**
 - 普通笔记本即可完成训练
 - 无需GPU加速
 - **成绩参考:**
 - 优秀: $MAE < 400$
 - 达标: $MAE < 500$
 - 基础: $MAE \approx 700$

2. 金融行业的应用场景 16:09

1) 客户流失分析与预警 24:12


- 客户流失与预警的场景与重要性

客户流失分析与预警




场景: 客户流失分析与预警

- 新客获取成本是老客户的5倍
- 同时老客户的价值大于一般的新客户 (习惯需要培养, 且价值需要提升)



- ① ② ③ ④ ⑤ ⑥ ⑦ ⑧ ⑨ ⑩ ⑪ ⑫ ⑬ ⑭ ⑮ ⑯ ⑰ ⑱ ⑲ ⑳ ㉑ ㉒ ㉓ ㉔ ㉕ ㉖ ㉗ ㉘ ㉙ ㉚ ㉛ ㉜ ㉝ ㉞ ㉟ ㊱ ㊲ ㊳ ㊴ ㊵ ㊶ ㊷ ㊸ ㊹ ㊺ ㊻ ㊼ ㊽ ㊾ ㊿
- **成本差异:** 新客获取成本是老客户的5倍, 老客户价值大于一般新客户 (需要培养使用习惯并提升价值)
- **行业案例:** 保险公司续保率约78%, 若降至20%将导致企业无法持续经营
- **典型场景:** 银行客户存款清零或APP连续30天未登录可判定为流失状态
- **客户流失预警模型 26:29**
 - **时间窗口设计:**
 - 观察窗口: 观测点前固定时长 (如6个月) 的行为数据
 - 表现窗口: 观测点后固定时长的流失状态数据
 - **数据构成:**
 - 特征数据 (X): 用户年龄、性别、地区、登录次数等历史行为
 - 标签数据 (Y): 后续时间段是否流失的二元分类结果
- **客户流失预警模型的应用逻辑 28:47**



- 建模阶段：用历史数据建立X→Y的预测关系
- 预测阶段：取当前时间点前N期数据预测未来N期流失概率
- 实施示例：以2025年9月20日为基准，用3月20日-9月20日数据预测至2026年3月19日的流失风险

● 例题1:客户购买预测 29:38


- 方法迁移：将流失预警模型框架应用于购买预测，仅需将Y改为"是否购买"
- 通用逻辑：任何"历史特征→未来行为"的预测问题均可套用此建模范式

2) 手机银行贷款页面优化 29:57

● 千人千面系统介绍 30:01

- 互联网特征：淘宝/抖音等平台通过海量商品和用户高频行为实现个性化推荐
- 核心要求：需要丰富的内容池（商品/资讯）和密集的用户交互数据支撑

● 银行端难以实现千人千面的原因 30:27



- 产品限制：金融产品种类有限（如贷款/理财等约10个主要品类）
- 行为低频：用户平均每月登录1-2次，远低于社交/电商平台的每日多次
- 数据颗粒度：单一用户行为轨迹稀疏，难以建立精准个人画像

● 银行端推荐系统：千人十面 31:49

- 聚类策略：将用户划分为10类典型群体（如老年人/留学生/上班族等）
- 地域细分：进一步区分北上广深与其他城市同类型用户
- 实现路径：通过群体行为特征而非个体特征进行推荐

● 银行端用户画像与推荐策略 32:54



- **画像维度：**
 - 基础属性：年龄+职业+地域
 - 行为特征：产品偏好+操作频率
- **推荐效果：**相比统一页面，分组推荐可使点击率提升5-30%
- **运营工具：**需配套半自动化配置系统支持快速调整推荐策略

3) 标签落地应用 33:46

- **标签落地应用：易车案例 33:47**

标签落地应用（易车案例）




-
- **推荐策略转变：**从全量推荐（所有人看到相同信息）转变为人群包定向推荐（不同群体看到定制化内容）
- **实施效果：**曝光量减少18%的情况下，点击量提升5%，点击率提升30%
- **人群包定义：**根据用户身份（如打工族、留学生）、行为数据等进行群体划分
- **案例细节：**易车作为汽车资讯平台，通过精准推荐实现业务指标优化
- **标签落地应用：手机银行贷款页面优化 34:43**

手机银行贷款页面优化




-
- **定向推送原理：**基于用户地域、客群特征和行为习惯匹配不同贷款产品
- **运营价值：**相当于为不同用户群体创建了多个定制化APP版本
- **技术实现：**通过半自动化运营工具实现个性化内容投放
- **例题1：客户流失分析与预警 35:03**

客户流失分析与预警




-
- **题目解析**
 - **业务背景：**新客获取成本是老客户的5倍，老客户价值更高
 - **模型结构：**包含观察窗口（历史数据）和预测窗口（未来表现）

- **关键指标**: 身份职业、资产情况、活跃度、交易情况、借贷情况
- **应用价值**: 提前识别潜在流失客户, 采取挽留措施
- **预测单个样本流失的可行性 35:28**
 - **预测粒度**: 模型可以预测单个客户流失概率 (类似二手车价格预测单个车辆)
 - **数据要求**: 需要足够样本量 (如15万辆二手车数据) 才能学习充分规律
 - **类比说明**: 与股票预测类似, 基于历史规律推断未来表现
- **预测时间点对模型准确性的影响 36:00**
 - **时间差异**: 训练使用历史"已知结果"数据, 预测面向未来时段
 - **模型前提**: 假设历史规律在未来仍有效 (类似技术分析预测股票)
 - **局限性**: 当历史规律失效时模型预测准确性下降
- **人群包的定义与应用 37:08**
 - **定义方法**: 可通过年龄、地域、性别等多维度组合定义 (如"北上广30-40岁月入2万+女性")
 - **运营价值**: 支持精准投放和定制化内容推送
 - **技术基础**: 与聚类分析概念相关, 将相似用户归为同一群体
- **例题2: 因客定价 38:09**



- **题目解析**
 - **定价依据**: 基于借款人信用、贡献度等因素差异化定价
 - **评分维度**: 包含工作信息 (单位类型、职位)、资产情况、负债比等
 - **客户分级**: 优质客户享受更低利率 (评分卡机制)

● 互联网行业与传统行业的个性化推荐策略 38:26



- **互联网行业**: 采用千人千面策略 (用户行为高频, 产品内容丰富)
- **传统行业**: 采用千人十面策略 (用户行为低频, 产品相对单一)
- **适用场景**: 金融、制造、快消等非互联网行业适合群体级推荐
- **技术实现**: 通过聚类分析处理低频行为数据

3. 快消行业的应用场景 39:24

1) 因客定价的场景: 贷款领域利率与额度的差异 39:26

- **差异化定价依据**: 利率可基于借款人信用评分、职业稳定性 (公务员/国企员工评分高于自由职业者)、资产状况 (房产/保险持有情况)、负债比 (家庭年收入与债务比例) 等维度进行差别化定价

- ## 2) 优质客户与普通客户的利率差异 40:09



某银行推出个人消费贷，采用“因客定价”策略，根据借款人的信用状况、贡献度等因素，差异化设定利率。

1. 优质客户：低利率

客户信息

姓名：张先生

信用评分: 850分 (分数区间: 350-950分)

贡献度：高（长期存款客户，持有银行理财产品）

职业：大型企业高管

收入：稳定且高于平均水平

定价逻辑

信用评分高，违约风险低。

对银行贡献度高，属于高价值客户。

职业和收入稳定，还款能力强。

利率设定

基准利率：5%

优惠利率：4.2%（基于客户信用和贡献度下调0.8个百分点）

- 优质客户特征：
 - 信用评分高（如850分，区间350-950）
 - 职业稳定（大型企业高管）
 - 贡献度高（长期存款客户，持有银行理财产品）
 - **利率优惠**：基准利率5%可下调至4.2%（优惠0.8个百分点）



2. 普通客户：较高利率

客户信息

姓名：李先生

信用评分: 650分 (分数区间: 350-950分)

贡献度：中（仅持有普通储蓄账户）

职业：自由职业者

收入：波动较大

定价逻辑

信用评分中等，有一定违约风险。

对银行贡献度一般，未达到优质客户标准。

职业和收入稳定性较差，还款能力存在不确定性。

利率设定

基准利率：5%

实际利率：6.5%（基于客户信用和贡献度上浮1.5个百分点）

- **普通客户特征：**
 - 信用评分中等（如650分）
 - 职业不稳定（自由职业者）
 - 贡献度一般（仅普通储蓄账户）
 - **利率上浮：**基准利率5%上浮至6.5%（增加1.5个百分点）
- **市场机制：**
 - 优质客户存在银行间竞争，促使利率走低
 - 普通客户因违约风险需通过高利率覆盖坏账损失（如小贷公司利率可达18%）

3) 评分卡模型：客户信息评分与信用等级 41:49



场景：因客定价

- 利率可以基于借款人的信用、贡献度等因素进行

差别化定价

优质客户 => 利率低一些

普通客户 => 利率高一些

优质客户的衡量可以参考信用评分卡


第一部分: 基本身份的信息			
0-18	0%	未婚	5%
18-24	2%	已婚	8%
25-29	8%	已婚有子女	10%
30-44	9%	已婚无子女	6%
45-54	8%	离异有子女	4%
55-68	3%	离异无子女	3%
60以上	3%		
本地户籍	10%	1年以内	2%
其他户籍	2%	1-3年(含)	6%
研究生及以上学历	10%	3-5年(含)	8%
大学	8%	5年以上	10%
大专	2%		

第一部分 工作信息					10	
工作单位	公共事业单位/银行/银行从业人员				11	
	是否公立大型/中型/小型企业				82	
	一般/股份制/股份制企业/私营企业/其他				83	
	全职/兼职				84	
职位	高级领导		10分	薪酬	高级领导	87
	中级领导		8分		中级领导	88
应聘工作时间	3个月	5分				89
	6个月	6分				90
	9个月	7分				91
	13个月	8分				92
	18个月	9分				93
	3年以上	10分				94
第二部分 家庭信息					95	
房产信息	自有房产	0分	租房房产 (万	50-100万	125	
	共有房产	10分	租房房产 (万	100-200万	126	
	租房房产	0分	租房房产 (万	200万以上	127	
	租房房产	0分	租房房产 (万	租房房产 (万	128	
保险信息	购买重大疾病/健康/财产/意外/其他保险/2年				87	
	购买重大疾病/健康/财产/意外/其他保险/3年				88	
	购买重大疾病/健康/财产/意外/其他保险/4年				89	
	购买重大疾病/健康/财产/意外/其他保险/5年				90	
第三部分 家庭资产					91	
负债比	5-10%			5分/14	92	
	10%-20%			8分/15	93	
	20%-30%			5分	94	
	30%-40%			10分/15	95	
	40%-50%			10分/15	96	
	60%以上			20分/30分	97	
第四部分 家庭收入					98	
家庭年收入	5-10万			5分/14	99	
	10-20万			8分/15	100	
	20-30万			10分/15	101	
	30-40万			10分/15	102	

评分维度：

- 基础信息：年龄（25-29岁得8分）、婚姻（已婚有子女得10分）、户籍（本地10分）
 - 工作信息：现单位工作年限（5年以上得10分）、职位（高级领导得分更高）
 - 资产信息：房产类型（全款房得分最高）、保险持有年限（2年以上加分）
 - **应用逻辑**：总分决定信用等级，直接影响贷款审批通过率和利率水平
- 4) 芝麻信用分：评分维度与业务应用 42:30
- **评分体系**：350-950分区间，700分以上属于良好信用
 - **评估维度**：
 - 身份特征（学历、职业等）
 - 履约历史（借贷还款记录）
 - 行为偏好（消费习惯）
 - **实际应用**：
 - 免押金服务（租车、共享充电宝）
 - 贷款优惠（高分用户可获得更低利率）
 - 临界值效应：600分可能是某些服务的授信门槛
- 5) 评分卡模型的逻辑回归算法 44:04
- **算法选择**：采用逻辑回归而非神经网络，主要考虑：
 - 可解释性强：能明确各特征项的权重系数
 - 业务友好：便于向客户解释评分构成（如"提高学历可增加XX分"）
 - **模型输出**：生成可视化的评分卡表格，业务人员可直接对照使用
4. 公司金融的应用场景 44:40

长尾客群营销



经营策略	客群大类	经营目标	经营事件	经营策略	配置产品
成熟期	理财产品到期类	客群维稳	理财到期	结合客户产品持仓及风险偏好，优先续投，其次赎回	权益基金/银行活期产品
	单一现金持仓	客群维稳	产品转化	利用产品转化提高整体收益率	权益基金/黄金账户
	资产归配	客群维稳	资产配置	用科学的资产配置理念引导客户进行全面的配置	金生利/权益基金/债券基金等
	预警流失模型客户	客群维稳	资产配置	定期回访切入，了解客户的后续资金安排情况，有针对性地进行给出合理建议，运用资产配置理念进行产品的配置。	资产配置的科学理念的应用
成长期	存款偏好客户	存款提升	定期回访	介绍我行的结构性存款或者大额存款，进行新资金的引入，增加客户的存款和AUM	结构性存款/大额存单
	存款偏好客户	存款提升	定期回访	介绍我行的结构性存款或者大额存款，进行新资金的引入，增加客户的存款和AUM	结构性存款/大额存单
	潜力资产模型客户	客群提升	定期回访	介绍达标的客户的权益体系，邀请客户升级卡等级	权益理财产品/卡权益体系
	三方客群	客群提升	三方回流	分析目前市场行情，建议客户合理进行资产的分布，降低整体的风险	权益类基金
预警期	国有行净转出	客群提升	资金转出	了解客户转出的原因，用我行的理财产品收益优势挽留转出的资金	高收益理财产品
	国有银行主账户	客群提升	服务邀约	综合介绍我行的财富管理优势，邀约客户体验。	高收益理财产品
	资产临界不达标	客群提升	定期回访	介绍达标的客户的权益体系，邀请客户达标享受更多的除	高收益理财产品/增值服务
	高有效代发	代发留存	代发工资/奖金	结合客户产品持仓及风险偏好，制定周期性的定投计划或者财富管理产品的引入，实现资产稳步增值	基金定投/零存整付/高收益理财产品
挽留期	大额流入	大额留存	大额转入	了解客户后续的资金使用安排，用财富产品锁定资金	高收益理财产品/流动性理财产品
	大额流出	资金挽留	大额转出	了解客户转出的原因，给予合理化建议，邀约客户转回。	高收益理财产品/流动性理财产品
	礼品类客户	权益提升	权益活动	利用营销活动提升客户的信任度和黏度，先建立关系	活动
	礼品类客户	权益提升	权益活动	利用活动提升客户的信任度和黏度，逐渐挖掘客户潜力。	活动

- **客群分类**：
 - 成熟期客户：理财产品到期转化、资产配置优化
 - 成长期客户：通过大额存单、结构性存款提升AUM（资产管理规模）
 - 懵懂期客户：通过营销活动建立初步关系
 - **差异化策略**：
 - 预警流失客户：定期回访+资产配置建议
 - 三方支付客户：引导资金回流至高收益理财产品
5. 长尾客群营销 45:50
- 1) 长尾客群营销对照表 46:03

长尾客群营销





经营策略	客群大类	经营目标	经营事件	经营策略	配置产品
成熟期	理财产品到期	客群维稳	理财到期	结合客户产品持仓及风险情况，优先续投，其次赎回	权益基金/银行理财产品
	单一现金持仓	客群维稳	产品转化	利用产品转化提高整体收益率	权益基金/货币基金
	资产缺配	客群维稳	资产配置	用科学的资产配置理念引导客户进行全面的配置	金生利/权益基金/货币基金等
	频繁流失模型客户	客群维稳	资产配置	定期回访切入，了解客户的后续资金安排情况，有针对性地进行组合建议，运用资产配置进行产品的锁定。	资产配置的科学理念的应用
成长期	存款偏好客户	存款提升	定期回访	介绍我行的结构性存款或者大额存款，进行新资金的引入，增加客户的存款和AUM	结构性存款/大额存单
	存款偏好客户	存款提升	定期回访	介绍我行的结构性存款或者大额存款，进行新资金的引入，增加客户的存款和AUM	结构性存款/大额存单
	潜力资产模型客户	客群提升	定期回访	介绍达标的客户的权益体系，邀请客户升级卡等级	高收益理财产品/卡权益体系
	三方客群	客群提升	三方回流	分析目前市场行情，建议客户合理进行资产的分布，降低整体的风险	权益类基金
苏醒期	国有行转出	客群提升	资金转出	了解客户转出的原因，用我行的理财产品收益优势模型转出的资金	高收益理财产品
	国有行主账户	客群提升	服务邀约	综合介绍我行的财富管理优势，邀约客户体验。	高收益理财产品
	资产临界不达标	客群提升	定期回访	介绍达标的客户的权益体系，邀请客户达标享受更多的权益	高收益理财产品/增值服务
	高有效代发	代发留存	代发工资/奖金	结合客户产品持仓及风险情况，制定周期性的定投计划或者财富产品的买入，实现资产资产平衡	基金定投/零存整付/高收益理财产品
懵懂期	大额流入	大额留存	大额转入	了解客户后续的资金使用安排，用财富产品锁定资金	高收益理财产品/流动性理财产品
	大额流出	资金挽回	大额转出	了解客户转出的原因，给予合理化建议，邀约客户转回。	高收益理财产品/流动性理财产品
	礼品型客户	权益提升	权益活动	利用营销活动提升客户的信任度和黏度，先建立关系	活动
	活动型客户	权益提升	权益活动	利用活动提升客户的信任度和黏度，逐渐挖掘客户潜力。	活动

- 四阶段模型：
 - 懵懂期：礼品型/活动型客户，以权益活动提升粘度
 - 苏醒期：处理代发、大额资金流动客户，通过产品锁定资金
 - 成长期：存款偏好、国有行转出客户，增加财富产品配置
 - 成熟期：理财到期、资产缺配客户，进行资产配置优化
- 策略匹配：每个阶段配置不同的经营事件和产品组合，如结构性存款、权益基金等

5) 基于潜力值及活跃度的细分 48:31

长尾客群营销（基于客户的潜力值及活跃度进行细分）



- 二维细分模型：
 - 纵轴：活跃度（低/中/高活跃层）
 - 横轴：潜力值（低/中/高潜力区域）
- 经营重点：
 - 强活跃层（15万）：线上经营为主，价值提升
 - 高活跃层（40万）：场景经营+批量人工
 - 中活跃层（55万）：功能开通+权益活动
 - 低活跃层（35万）：权益活动唤醒

6) 细分策略的重要性 48:44

- 运营核心：不断进行客户细分，避免一刀切的营销方案
- 行业经验：来自阿里等互联网公司的实践表明，业绩提升的关键在于持续细化客户分群
- 实施要点：为每个细分群体设计专属的决策方案，提高策略匹配度

7) 细分策略与AI的结合 49:23



- AI应用场景：
 - 客户画像识别：自动判断客户所属的客群类型
 - 策略生成：基于经营手册自动匹配合适的产品和策略
- 实施路径：将细分策略整理成结构化手册，作为AI决策的基础规则
- 效果预期：实现真正的精细化运营，提升营销效率和客户体验

6. 贷款商机挖掘 50:27

1) 分行级存量客户数据库建立

贷款商机挖掘


建立分行级存量客户数据库

一个数据库能装入分行XXX万零售客户，

一期建设若干授信敏感变量，包含个人反洗钱九要素，分行近一年12个月没有AUM数，四个季度结息数，以及是否为小微企业相关标识和信用卡持有情况

由于信用卡本身做了征信查询授权，就可以利用信用卡的贷后征信查询做信用模型，数据库的变量做白名单筛选。将总行产品预审模型到分行数据库跑数，生成最终准客户名单。

最终挑选出存量客户中符合贷款产品的准客户，交由三支队伍中的存量经营团队线下营销



- 数据库规模：可容纳分行XXX万零售客户，一期建设包含个人反洗钱九要素等授信敏感变量
 - 关键变量：
 - 近12个月无AUM数据
 - 四个季度结息数
 - 小微企业标识
 - 信用卡持有情况（利用贷后征信查询授权建立信用模型）
 - 筛选流程：通过总行产品预审模型跑数生成准客户名单，最终由存量经营团队线下营销
- ### 2) 对公营销需求与解决方案 50:58
- 市场现状：
 - 企业贷款需求增长但增量客户获取困难
 - 客户经理面临KPI考核压力
 - 创新思路：从零售客户中挖掘潜在企业主（企业法人个人账户持有者）
 - 数据基础：分行全量客户池380万户，识别出13万企业主画像客户
- ### 3) 企业主识别与贷款营销 51:19

贷款商机挖掘



建立分行级存量客户数据库

一个数据库能装入分行XXX万零售客户，

一期建设若干授信敏感变量，包含个人反洗钱九要素，分行近一年12个月没有AUM数，四个季度结总数，以及是否为小微企业相关标识和信用卡持有情况

由于信用卡本身做了征信查询授权，就可以利用信用卡的贷后征信查询做信用模型，数据库的变量做白名单筛选。将总行产品预审模型到分行数据库跑数，生成最终准客户名单。

最终挑选出存量客户中符合贷款产品的准客户，交由三支队伍中的存量经营团队线下营销



分行存量零售客户
XXX万




小微标识客户名单
XX万



白名单

- 识别逻辑：企业法人可能持有银行个人账户但未开立对公账户
 - 筛选效率：
 - 初筛：380万→13万（基于企业主身份识别）
 - 二次过滤：13万→4万（预审批模型筛选）
 - 营销效果：转化率从盲打1%提升至定向营销4%
- 4) AI与算法在贷款商机挖掘中的应用 53:11
- 核心价值：通过多维度过滤机制提升营销精准度
 - 技术本质：AI的本质是优质客户过滤工具，替代人工盲筛的低效方式
 - 应用场景：身份识别、预审批模型、征信查询、营销响应分析等环节
- 5) 贷款商机挖掘的过滤机制 54:00

因客定价



场景：因客定价

- 利率可以基于借款人的信用、贡献度等因素进行差别化定价

优质客户 => 利率低一些

普通客户 => 利率高一些

优质客户的衡量可以参考信用评分卡

第一部分 基本身份的信息			
0-18	0分	未婚	5分
18-24	1分	已婚	5分
25-29	2分	已婚有子女	10分
30-34	3分	已婚有子女	10分
35-39	4分	已婚有子女	10分
40-44	5分	已婚有子女	10分
45-49	6分	已婚有子女	10分
50-54	7分	已婚有子女	10分
55-59	8分	已婚有子女	10分
60-64	9分	已婚有子女	10分
65-69	10分	已婚有子女	10分
70-74	11分	已婚有子女	10分
75-79	12分	已婚有子女	10分
80-84	13分	已婚有子女	10分
85-89	14分	已婚有子女	10分
90-94	15分	已婚有子女	10分
95-99	16分	已婚有子女	10分
100-104	17分	已婚有子女	10分
105-109	18分	已婚有子女	10分
110-114	19分	已婚有子女	10分
115-119	20分	已婚有子女	10分
120-124	21分	已婚有子女	10分
125-129	22分	已婚有子女	10分
130-134	23分	已婚有子女	10分
135-139	24分	已婚有子女	10分
140-144	25分	已婚有子女	10分
145-149	26分	已婚有子女	10分
150-154	27分	已婚有子女	10分
155-159	28分	已婚有子女	10分
160-164	29分	已婚有子女	10分
165-169	30分	已婚有子女	10分
170-174	31分	已婚有子女	10分
175-179	32分	已婚有子女	10分
180-184	33分	已婚有子女	10分
185-189	34分	已婚有子女	10分
190-194	35分	已婚有子女	10分
195-199	36分	已婚有子女	10分
200-204	37分	已婚有子女	10分
205-209	38分	已婚有子女	10分
210-214	39分	已婚有子女	10分
215-219	40分	已婚有子女	10分
220-224	41分	已婚有子女	10分
225-229	42分	已婚有子女	10分
230-234	43分	已婚有子女	10分
235-239	44分	已婚有子女	10分
240-244	45分	已婚有子女	10分
245-249	46分	已婚有子女	10分
250-254	47分	已婚有子女	10分
255-259	48分	已婚有子女	10分
260-264	49分	已婚有子女	10分
265-269	50分	已婚有子女	10分
270-274	51分	已婚有子女	10分
275-279	52分	已婚有子女	10分
280-284	53分	已婚有子女	10分
285-289	54分	已婚有子女	10分
290-294	55分	已婚有子女	10分
295-299	56分	已婚有子女	10分
300-304	57分	已婚有子女	10分
305-309	58分	已婚有子女	10分
310-314	59分	已婚有子女	10分
315-319	60分	已婚有子女	10分
320-324	61分	已婚有子女	10分
325-329	62分	已婚有子女	10分
330-334	63分	已婚有子女	10分
335-339	64分	已婚有子女	10分
340-344	65分	已婚有子女	10分
345-349	66分	已婚有子女	10分
350-354	67分	已婚有子女	10分
355-359	68分	已婚有子女	10分
360-364	69分	已婚有子女	10分
365-369	70分	已婚有子女	10分
370-374	71分	已婚有子女	10分
375-379	72分	已婚有子女	10分
380-384	73分	已婚有子女	10分
385-389	74分	已婚有子女	10分
390-394	75分	已婚有子女	10分
395-399	76分	已婚有子女	10分
400-404	77分	已婚有子女	10分
405-409	78分	已婚有子女	10分
410-414	79分	已婚有子女	10分
415-419	80分	已婚有子女	10分
420-424	81分	已婚有子女	10分
425-429	82分	已婚有子女	10分
430-434	83分	已婚有子女	10分
435-439	84分	已婚有子女	10分
440-444	85分	已婚有子女	10分
445-449	86分	已婚有子女	10分
450-454	87分	已婚有子女	10分
455-459	88分	已婚有子女	10分
460-464	89分	已婚有子女	10分
465-469	90分	已婚有子女	10分
470-474	91分	已婚有子女	10分
475-479	92分	已婚有子女	10分
480-484	93分	已婚有子女	10分
485-489	94分	已婚有子女	10分
490-494	95分	已婚有子女	10分
495-499	96分	已婚有子女	10分
500-504	97分	已婚有子女	10分
505-509	98分	已婚有子女	10分
510-514	99分	已婚有子女	10分
515-519	100分	已婚有子女	10分
520-524	101分	已婚有子女	10分
525-529	102分	已婚有子女	10分
530-534	103分	已婚有子女	10分
535-539	104分	已婚有子女	10分
540-544	105分	已婚有子女	10分
545-549	106分	已婚有子女	10分
550-554	107分	已婚有子女	10分
555-559	108分	已婚有子女	10分
560-564	109分	已婚有子女	10分
565-569	110分	已婚有子女	10分
570-574	111分	已婚有子女	10分
575-579	112分	已婚有子女	10分
580-584	113分	已婚有子女	10分
585-589	114分	已婚有子女	10分
590-594	115分	已婚有子女	10分
595-599	116分	已婚有子女	10分
600-604	117分	已婚有子女	10分
605-609	118分	已婚有子女	10分
610-614	119分	已婚有子女	10分
615-619	120分	已婚有子女	10分
620-624	121分	已婚有子女	10分
625-629	122分	已婚有子女	10分
630-634	123分	已婚有子女	10分
635-639	124分	已婚有子女	10分
640-644	125分	已婚有子女	10分
645-649	126分	已婚有子女	10分
650-654	127分	已婚有子女	10分
655-659	128分	已婚有子女	10分
660-664	129分	已婚有子女	10分
665-669	130分	已婚有子女	10分
670-674	131分	已婚有子女	10分
675-679	132分	已婚有子女	10分
680-684	133分	已婚有子女	10分
685-689	134分	已婚有子女	10分
690-694	135分	已婚有子女	10分
695-699	136分	已婚有子女	10分
700-704	137分	已婚有子女	10分
705-709	138分	已婚有子女	10分
710-714	139分	已婚有子女	10分
715-719	140分	已婚有子女	10分
720-724	141分	已婚有子女	10分
725-729	142分	已婚有子女	10分
730-734	143分	已婚有子女	10分
735-739	144分	已婚有子女	10分
740-744	145分	已婚有子女	10分
745-749	146分	已婚有子女	10分
750-754	147分	已婚有子女	10分
755-759	148分	已婚有子女	10分
760-764	149分	已婚有子女	10分
765-769	150分	已婚有子女	10分
770-774	151分	已婚有子女	10分
775-779	152分	已婚有子女	10分
780-784	153分	已婚有子女	10分
785-789	154分	已婚有子女	10分
790-794	155分	已婚有子女	10分
795-799	156分	已婚有子女	10分
800-804	157分	已婚有子女	10分
805-809	158分	已婚有子女	10分
810-814	159分	已婚有子女	10分
815-819	160分	已婚有子女	10分
820-824	161分	已婚有子女	10分
825-829	162分	已婚有子女	10分
830-834	163分	已婚有子女	10分
835-839	164分	已婚有子女	10分
840-844	165分	已婚有子女	10分
845-849	166分	已婚有子女	10分
850-854	167分	已婚有子女	10分
855-859	168分	已婚有子女	10分
860-864	169分	已婚有子女	10分
865-869	170分	已婚有子女	10分
870-874	171分	已婚有子女	10分
875-879	172分	已婚有子女	10分
880-884	173分	已婚有子女	10分
885-889	174分	已婚有子女	10分
890-894	175分	已婚有子女	10分
895-899	176分	已婚有子女	10分
900-904	177分	已婚有子女	10分
905-909	178分	已婚有子女	10分
910-914	179分	已婚有子女	10分
915-919	180分	已婚有子女	10分
920-924	181分	已婚有子女	10分
925-929	182分	已婚有子女	10分
930-934	183分	已婚有子女	10分
935-939	184分	已婚有子女	10分
940-944	185分	已婚有子女	10分
945-949	186分	已婚有子女	10分
950-954	187分	已婚有子女	10分
955-959	188分	已婚有子女	10分
960-964	189分	已婚有子女	10分
965-969	190分	已婚有子女	10分
970-974	191分	已婚有子女	10分
975-979	192分	已婚有子女	10分
980-984	193分	已婚有子女	10分
985-989	194分	已婚有子女	10分
990-994	195分	已婚有子女	10分
995-999	196分	已婚有子女	10分
1000-1004	197分	已婚有子女	10分
1005-1009	198分	已婚有子女	10分
1010-1014	199分	已婚有子女	10分
1015-1019	200分	已婚有子女	10分
1020-1024	201分	已婚有子女	10分
1025-1029	202分	已婚有子女	10分
1030-1034	203分	已婚有子女	10分
1035-1039	204分	已婚有子女	10分
1040-1044	205分	已婚有子女	10分
1045-1049	206分	已婚有子女	10分
1050-1054	207分	已婚有子女	10分
1055-1059	208分	已婚有子女	10分
1060-1064	209分	已婚有子女	10分
1065-1069	210分	已婚有子女	10分
1070-1074	211分	已婚有子女	10分
1075-1079	212分	已婚有子女	10分
1080-1084	213分	已婚有子女	10分
1085-1089	214分	已婚有子女	10分
1090-1094	215分	已婚有子女	10分
1095-1099	216分	已婚有子女	10分
1100-1104	217分	已婚有子女	10分
1105-1109	218分	已婚有子女	10分
1110-1114	219分	已婚有子女	10分
1115-1119	220分	已婚有子女	10分
1120-1124	221分	已婚有子女	10分
1125-1129	222分	已婚有子女	10分
1130-1134	223分	已婚有子女	10分
1135-1139	224分	已婚有子女	10分
1140-1144	225分	已婚有子女	10分
1145-1149	226分	已婚有子女	10分
1150-1154	227分	已婚有子女	10分
1155-1159	228分	已婚有子女	10分
1160-1164	229分	已婚有子女	10分
1165-1169	230分	已婚有子女	10分
1170-1174	231分	已婚有子女	10分
1175-1179	232分	已婚有子女	10分
1180-1184	233分	已婚有子女	10分
1185-1189	234分	已婚有子女	10分
1190-1194	235分	已婚有子女	10分
1195-1199	236分	已婚有子女	10分
1200-1204	237分	已婚有子女	10分
1205-1209	238分	已婚有子女	10分
1210-1214	239分	已婚有子女	10分
1215-1219	240分	已婚有子女	10分
1220-1224	241分	已婚有子女	10分
1225-1229	242分	已婚有子女	10分
1230-1234	243分	已婚有子女	10分
1235-1239	244分	已婚有子女	10分
1240-1244	245分	已婚有子女	10分
1245-1249	246分	已婚有子女	10分
1250-1254	247分	已婚有子女	10分
1255-1259	248分	已婚有子女	10分
1260-1264	249分	已婚有子女	10分
1265-1269	250分	已婚有子女	10分
1270-1274	251分	已婚有子女	10分
1275-1279	252分	已婚有子女	10分
1280-1284	253分	已婚有子女	10分
1285-1289	254分	已婚有子女	10分
1290-1294	255分	已婚有子女	10分
1295-1299	256分	已婚有子女	10分
1300-1304	257分	已婚有子女	10分
1305-1309	258分	已婚有子女	10分
1310-1314	259分	已婚有子女	10分
1315-1319	260分	已婚有子女	10分
1320-1324	261分	已婚有子女	10分
1325-1329	262分	已婚有子女	10分
1330-1334	263分	已婚有子女	10分
1335-1339	264分	已婚有子女	10分
1340-1344	265分	已婚有子女	10分
1345-1349	266分	已婚有子女	10分
1350-1354	267分	已婚有子女	10分
1355-1359	268分	已婚有子女	10分
1360-1364	269分	已婚有子女	10分
1365-1369	270分	已婚有子女	10分
1370-1374	271分	已婚有子女	10分
1375-1379	272分	已婚有子女	10分
1380-1384	273分	已婚有子女	10分
1385-1389	274分	已婚有子女	10分
1390-1394	275分	已婚有子女	10分
1395-1399	276分	已婚有子女	10分
1400-1404	277分	已婚有子女	10分
1405-1409	278分	已婚有子女	10分
1410-1414	279分	已婚有子女	10分
1415-1419	280分	已婚有子女	10分
1420-1424	281分	已婚有子女	10分
1425-1429	282分	已婚有子女	10分
1430-1434	283分	已婚有子女	10分
1435-1439	284分	已婚有子女	10分
1440-1444	285分	已婚有子女	10分
1445-1449	286分	已婚有子女	10分
1450-1454	287分	已婚有子女	10分
1455-1459	288分	已婚有子女	10分
1460-1464	289分	已婚有子女	10分
1465-1469	290分	已婚有子女	10分
1470-1474	291分	已婚有子女	10分
1475-1479	292分	已婚有子女	10分
1480-1484	293分	已婚有子女	10分
1485-1489	294分	已婚有子女	10分
1490-1494	295分	已婚有子女	10分
1495-1499	296分	已婚有子女	10分
1500-1504	297分	已婚有子女	10分
1505-1509	298分	已婚有子女	10分
1510-1514	299分	已婚有子女	10分
1515-1			

贷款商机挖掘



零售大表：客户姓名，年龄，收入，人生阶段，资产层级，职业.....

企业客户表：客户姓名，年龄，企业名称，行业经营范围，企业成立时间，持股比例，是否专精特新企业纳税评级

字段所属表：所属库名，表名，字段名称，中文名称，字段类型，字段描述，字段备注，脱敏类型，安全等级，允许空值，统计口径
是否主键，是否码值

意愿表：号码，姓名，性别，年龄，是否纳税A评级，营销响应分

159XXXX	张飞	男	50	A	615
158XXXX	cy	男	38	A	625

- - 需求触发点：监测客户近期征信查询记录（贷款前常规行为）
 - 数据支撑：
 - 零售大表包含客户姓名、年龄、收入等20+字段
 - 企业客户表记录行业、成立时间、纳税评级等关键信息
 - 进阶筛选：在4万预审通过客户中识别有即时贷款需求者
- 8) 营销响应模型与数据复盘 57:05

贷款商机挖掘



零售大表：客户姓名，年龄，收入，人生阶段，资产层级，职业.....

企业客户表：客户姓名，年龄，企业名称，行业经营范围，企业成立时间，持股比例，是否专精特新企业纳税评级


字段所属表：所属库名，表名，字段名称，中文名称，字段类型，字段描述，字段备注，脱敏类型，安全等级，允许空值，统计口径
是否主键，是否码值

意愿表：号码，姓名，性别，年龄，是否纳税A评级，营销响应分

159XXXX	张飞	男	50	A	615
158XXXX	cy	男	38	A	625

- - 模型构建：基于历史营销数据建立响应预测模型
 - 评分设置：1-1000分区间，520分以上视为高响应客户
 - 最终筛选：4万→1万（响应分>520），转化率进一步优化
- 9) 漏斗模型与数据决策 58:19
- 模型本质：逐层过滤的决策机制（380万→13万→4万→1万）
 - 技术选型：
 - 数据决策使用可解释的小模型（逻辑回归、决策树）
 - 大模型用于AI编程（构建小模型）和智能交互（需求理解）
- 10) 大模型私域部署与并发处理 58:32
- 部署方案：
 - 基础版：千亿3的8b模型（80亿参数）
 - 进阶版：32b模型（320亿参数）
 - 并发处理：50万用户量按100并发计算，需多卡部署
- 11) 渠道运营与商圈生意机会地图 01:04:13

商圈生意机会地图



基于GeoHash网格的区域，计算区域的竞争压力指数（网点密集度）



结合人口密度分布，计算区域网点的生意机会地图

-
- **数据维度：**
 - 常住人口数量及趋势
 - 区域消费偏好与等级
 - 竞品网点分布密度
- **选址策略：**采用蜂窝图（六边形）模拟近似圆分析区域覆盖
- 12) 商圈数据采集与竞品分析 01:05:06
- **数据来源：**
 - 第三方人口统计数据
 - 外卖平台商户订单量
- **竞品关注：**麦当劳案例中重点监测肯德基、华莱士等同类品牌
- 13) 金融风控模型与数据分析 01:08:13

金融风控模型




场景：金融数据分析与风险控制

在信贷领域中存在信用卡违约和欺诈的风险，通过用户行为数据，分析申请借款用户的信用状况，来判断是否存在逾期。

通过分析交易时间、交易金额、收款方等多维度数据，我们还可以对信用卡是否被盗刷进行预测，防止信用卡被盗刷的风险

此外，通过预测模型，我们还可以分析出哪些因素容易导致违约，从而加强产品的设计



-
- **风险类型：**
 - 信用卡违约预测
 - 盗刷行为识别（基于交易时间、金额、收款方等多维度）
- **模型输出：**识别易违约特征以优化产品设计
- 7. 金融风控模型 01:08:25

金融风控模型

评分卡模型：

- 评分卡模型是常用的金融风控手段之一
- 风险，就是风险控制。我们采取各种措施和方法，减少风险发生的可能性，或风险发生时造成的损失
- 根据客户的各种属性行为数据，利用信用评分模型，对客户的使用行为评分，从而决定是否给予授信，授信的额度和利率，减少在金融交易中存在的交易风险
- 按照不同的业务阶段，可以分为三种：

贷前：申请评分卡（Application score card），称为A卡

贷中：行为评分卡（Behavior score card），称为B卡

贷后：催收评分卡（Collection score card），称为C卡

Thinking: A卡+B卡+C卡的数据源有何区别？

- 1) 外部征信数据是A卡中用户的主要数据
- 2) 对于复贷用户，已经有了历史平台表现，所以B卡通常不会再次查询用户的外部数据，而是利用历史平台表现 -> 节省成本
- 3) C卡不会再查询用户外部征信数据，主要利用历史贷款过程中，催收人员记录的用户表现作为主要数据

-
- **核心作用：**通过客户属性和行为数据建立信用评分，决定授信额度与利率，降低金融交易风险

- 分类标准：
 - A卡（申请评分卡）：贷前阶段，主要使用外部征信数据
 - B卡（行为评分卡）：贷中阶段，利用历史平台表现数据，节省二次查询成本
 - C卡（催收评分卡）：贷后阶段，基于催收记录的用户表现数据
- 数据差异：
 - 复贷用户跳过外部数据查询（B卡）
 - 催收阶段仅依赖内部行为记录（C卡）

8. 制造行业的应用场景 01:09:19

1) 螺栓扭矩曲线识别与缺陷检测 01:09:31

螺栓扭矩曲线识别与缺陷检测




业务场景：

螺栓是否拧紧对于汽车安全至关重要


现在的方法：技术人员只检测最终点是否在某个范围之内

可能的问题：

实际上，螺栓需要经过一个平台期，再最终达到规定的范围窗口内，安全质量会更高。否则只检测最终点，而没有达到平台期，可能多年之后会有安全隐患



-
- 传统方法缺陷：仅检测最终力矩值（如20 - 25N窗口），忽略平台期存在安全隐患
- 创新解决方案：
 - 曲线特征工程：
 - 连续上升点数量
 - 下降点数量及幅度（>30%阈值）
 - 平台期斜率变化
 - 模型构建：
 - 标记正常/缺陷样本（y=0/1）
 - 采用决策树、逻辑回归、随机森林、XGBoost等分类模型
- 数据采集：通过螺栓枪传感器实时记录力矩和拉伸度



-
- 技术要点：
 - 非图像识别方案，避免复杂纹理处理
 - 特征工程优于端到端深度学习方案
 - 类似二手车价格预测的业务建模思路


2) 车身表面缺陷检测 01:14:13

车身表面缺陷检测



缺陷检测:

- 缺陷样本少的情况 => 机器视觉算法
- 缺陷样本多的情况 => 神经网络算法




-
- **检测原理:**
 - 使用条形强光反射观测表面形变
 - 光线扭曲指示缺陷位置
- **技术选型:**
 - 少量样本: 传统机器视觉算法
 - 充足样本: CNN神经网络 (如YOLO)
- **实施要点:**
 - 简化图像识别复杂度 (专注光反射模式)
 - 需处理颜色、光线、角度等干扰因素

车身表面缺陷检测



机器视觉算法




神经网络算法

-
- **行业认知:**
 - 传统AI (如视觉检测) 仍具不可替代性
 - 大模型降低使用门槛但存在幻觉问题
- **实践建议:**
 - 关键决策采用小模型保证稳定性
 - 大模型用于智能交互和模型开发辅助
 - 构建AI Agent结合LLM与专业工具链

9. 快消行业的应用场景 01:19:57

1) 门店补货与销量预测 01:20:11

业务对于未来门店订货的期望



- **业务需求**：降低缺货损失、提升订货效率、精准预估、减轻清货压力、接货前库存存量低
 - **问题本质**：通过预测销量实现智能补货，以5000家门店为例，需预测每家门店次日各产品进货量（如麦当劳的汉堡、薯条、牛肉饼等）
 - **解决方案框架**：建立预测模型，核心是收集影响销量的多维度数据
- 2) 销量预测的影响因素 01:22:25
- **核心数据维度**：
 - **历史数据**：过去每家门店每天每个产品的销量
 - **环境因素**：天气、特殊事件（如疫情）、节假日日期
 - **营销活动**：促销活动、品牌推广
 - **门店属性**：地理位置（新疆/北京/上海）、开业时长、装修风格、座位数、营业时间（24小时或8:00-22:00）
- 3) 预测模型的选择 01:24:35
- **模型类型**：回归模型（因预测目标 y 为连续数值）
 - **候选算法**：
 - 决策树
 - 线性回归
 - 随机森林
 - XGBoost/CatBoost（更精确选择）
 - **特征工程**： x 为各类影响因素， y 为销量，需找到关键 x 才能准确预测
- 4) 预测结果分类与原因 01:25:50
- **预测差异现象**：老店预测准，新店预测不准
 - **根本原因**：
 - 老店有充足历史数据（数据稳定性高）
 - 新店缺乏历史数据（冷启动问题）
- 5) 新店预测与对标 01:26:42
- **解决方案**：
 - 老店模型：直接使用自身历史数据
 - 新店模型：寻找相似老店进行数据迁移（如新店A对标老店B，用B的下日销量预测A的销量）
 - **预期管理**：对新店的预测准确度要求应适当降低
- 6) AI项目流程 01:27:30
- **价值定位**：供应链补货优化，减少库存
 - **问题定义**：销量预测
 - **方案设计**：
 - 确定AI任务类型（回归任务）
 - 特征工程（收集各类影响因素）
 - 模型细分（区分老店/新店模型）
- 7) 回归任务与特征 01:28:22
- **任务特点**：预测连续数值（如价格、销量）
 - **特征要求**：需包含所有可能影响 y 的关键因素（历史数据+环境+活动+门店属性等）
- 8) 老店和新店模型 01:29:12
- **模型分化**：
 - 老店模型：数据充分，可直接预测
 - 新店模型：需通过相似老店数据进行冷启动
- 9) 例题1:老店数据对新店模型冷启动的帮助 01:29:47
- **实现方式**：
 - 将相似老店的历史数据迁移至新店

- 使用简单模型（因数据量有限）
 - 等价处理：将新店A的预测值用相似老店B的下日销量代替
10. 回归模型中如何确定用哪种算法更好 01:32:12
- 1) 回归模型的分类及策略 01:32:27
- **可解释性优先：**
 - 适用场景：不追求极致精度时
 - 推荐算法：线性回归、决策树
 - **精度优先：**
 - 推荐算法：XGBoost/LightGBM
 - 大数据量场景：神经网络（如15万条的二手车价格预测）
- 2) 回归模型与其他模型的任务区别 01:33:36
- **模型选择原则：**根据任务类型决定
 - 回归模型：预测连续值（价格、销量）
 - 聚类分析：自动分类
 - 关联分析：发现规律组合
 - 链接分析：识别影响力节点
- 3) 回归模型的定义与典型案例 01:34:37
- **本质特征：**预测输出为任意实数值
 - **典型场景：**
 - 房价预测
 - 车价预测
 - 销量预测
- 4) 神经网络预测的实现方式 01:35:15
- **实施要点：**
 - 明确特征和预测目标
 - 通过Agent（如GPT）自动生成代码
 - 关键是要准确描述任务需求
11. 分类模型选择 01:35:50
- 1) 多属性分类场景
- **适用场景：**当需要根据材料的名称、规格、技术参数等多个属性进行类别识别时，属于典型的分类问题
 - **模型选择策略：**与回归模型本质相同，区别仅在于最终结果的转换方式
- 2) 模型精度选择
- **精度优先：**数据量充足时可选择复杂模型（如神经网络）以获得更高精度
 - **效率优先：**不追求精度时可选用逻辑回归等简单模型
 - **核心原则：**分类与回归模型本质相通，可根据实际需求灵活转换
12. 判断回归模型标准 01:36:56
- 1) 模型选择标准
- **精度导向：**优先选择复杂模型（如神经网络），但需注意过拟合风险
 - **解释性导向：**报告类需求应选用简单模型（如线性回归），因其具有更好的可解释性和稳定性
 - **平衡原则：**模型复杂度与业务需求需匹配，不存在绝对最优解
- 2) 稳定性考量
- **简单优势：**模型越简单通常稳定性越好，适合需要长期稳定输出的场景
 - **复杂代价：**高精度模型可能牺牲稳定性和可解释性，需权衡利弊
13. 数据有缺失时评分卡使用 01:37:35
- 1) 缺失数据处理
- **特征化处理：**缺失数据本身可作为特征，常见于银行信贷评分场景

- **标记方法**：为缺失数据创建单独标记项，保留原始数据分布信息
- 2) 行业特殊案例
- **制造业场景**：备件采购频次低、偶发性强时，需特别注意数据稀疏性问题
 - **应对策略**：可采用集成学习方法或增加数据采集周期来提高模型鲁棒性
14. 制造行业偶发性事件影响大的策略 01:38:21
- 1) 策略一：选择合适的颗粒度 01:38:39
- **时间维度选择**：对于偶发性事件，不宜采用天或周等细粒度时间维度，建议使用月、季度甚至半年为周期进行统计，这样数据信号会更稳定。
 - **类比说明**：就像脉冲信号难以预测具体发生时刻，但拉长时间周期后信号会趋于稳定。
- 2) 策略二：数据量小不均衡时考虑人工规则 01:40:07
- **模型适用性**：当数据量少且分布极度不均衡时，不建议直接使用复杂模型，可考虑人工制定规则。
 - **案例对比**：以头条金融事业部审计为例，神经网络小组因数据不足需人工造数据，而规则小组通过专家经验直接制定核查规则效果更稳定。
- 3) 例题1:决策树模型预测结果解释 01:41:52
- **参数设置**：决策树深度建议控制在3-7层（最佳实践为4层），过深会降低可解释性。
 - **解释方法**：通过条件组合呈现预测逻辑，例如"年龄30-50岁+男性+沿海一线城市→贷款通过率高"这样的规则化表达。
 - **应用示例**：实际业务中可通过调整树深度平衡预测精度与可解释性需求。
- 4) 预测模型与WMS系统结合思路 01:42:56
- **系统集成原则**：保持原有业务流程，仅将人工填写环节替换为AI预测输出。
 - **实施要点**：
 - 需预留容错空间（如允许前期预测存在10-20%误差）
 - 避免人工干预预测结果
 - 参考历史案例中100家门店的渐进式落地经验
15. 量化交易回测的数据选择 01:44:37
- **周期选择标准**：三年或一年数据的选择取决于历史阶段与当前市场的逻辑相似度，而非固定时长。
 - **颗粒度选择**：四小时数据与日数据各有优势，关键看哪个时间单位能更好反映完整的市场波动周期。
 - **类比说明**：如同预测楼盘走势，需寻找历史上与当前市场特征高度相关的时期作为参考。
16. 神经网络的精度与其他模型 01:46:24
- **性能对比**：
 - 神经网络：参数量大、数据需求高（需参数量平方级数据）、理论上限更高
 - XGBoost：参数量适中、中等数据量下表现稳定
 - **选择建议**：
 - 数据量有限时优先选择XGBoost
 - 具备海量数据且需挖掘复杂模式时考虑神经网络
 - **技术原理**：神经网络精度优势源于其更高的参数容量和特征组合能力。
17. 相关性判断 01:47:47
- **特征工程方法**：提取关键特征构建特征向量（如GDP、就业率、汇率等宏观经济指标）
 - **计算方式**：通过向量夹角计算相似度，公式为 $\cos\theta = \frac{X \cdot Y}{|X||Y|}$
 - **实施步骤**：
 - 量化历史行情特征（向量 $X = [x_1, x_2, x_3]$ ）


- 量化当前行情特征（向量 $Y = [y_1, y_2, y_3]$ ）
 - 计算余弦相似度判断相关性强度
 - **应用场景：**适用于市场周期识别、风险预警等需要历史参照的决策场景
18. 神经网络需要多少数据量 01:49:14
- **数据量非固定值：**神经网络所需数据量并非固定数值，主要取决于模型规模
 - **ImageNet案例：**ImageNet挑战赛使用约1500万-2300万张图像，对应大规模参数神经网络
 - **二手车价格案例：**10万个数据样本可搭建2-4层神经网络，每层200-400个神经元（总神经元约1000-2000个）
 - **核心关系：**数据量与网络复杂度呈正相关，数据量越大可支持更复杂的网络结构

19. 神经网络与树模型的泛化能力 01:51:05

- **神经网络优势：**
 - **拟合能力：**可通过权重调整实现复杂数据拟合
 - **规律发现：**擅长捕捉隐藏的交叉特征（如"上海女性夜间消费偏好"等复合规律）
- **决策树特点：**
 - **简单规律：**对清晰明确的规律识别效率更高
 - **复杂度局限：**拟合能力弱于神经网络，不适合高度非线性关系
- **选择原则：**
 - 简单规律优先使用决策树等简单模型
 - 复杂/隐含规律推荐使用神经网络
 - 关键判断标准是目标规律的复杂程度

20. 神经网络的层级 01:53:53

1) 神经网络的层级结构 01:54:00




- **传播机制：**神经网络是向前传播的逻辑结构，由多层神经元组成，信息从第一层逐层传递至输出层y
- **层级特点：**
 - 第一层接收原始信息并进行特征处理
 - 深层网络可达数百至上千层，用于处理复杂信息
- **适用场景：**
 - 特征维度少（10-20维）时不宜使用
 - 数据量小、规律简单时应选择简单模型

2) 过拟合现象 01:55:17

- **定义：**模型过度记忆训练数据中的非本质特征，导致泛化能力下降
- **典型表现：**
 - 类似"路径依赖"，如错误关联选择题答案顺序（记"选B后必选C"的伪规律）
 - 在二手车场景中机械记忆特定组合的价格（如"某条件下必是12000元"）
- **本质原因：**
 - 过度依赖不可靠特征


- 将训练数据噪声当作真实规律
- **避免原则：**
 - 模型复杂度应与问题复杂度匹配
 - 复杂模型需要足够数据量支撑（如神经网络）

3) 例题2:AI应用场景思考 01:57:24



- **题目解析**
 - **分析式AI典型场景：**
 - 客户流失预警
 - 反洗钱监测
 - 贷款质量分析
 - **生成式AI典型场景：**
 - 贷款页面优化
 - 智能推荐系统
 - **制造业特殊场景：**
 - 供应链补货预测（需考虑数据稀疏性）
 - 缺陷检测（计算机视觉应用）

21. 二手车交易价格预测 01:57:37



- **关键特征：**
 - 匿名特征v0-v14（15个衍生特征）
 - 结构化字段：功率、里程、损坏状态等
- **模型选择原则：**
 - **回归任务本质：**因变量y为连续型价格数据
 - **算法选择标准：**
 - 可解释性优先：线性回归、决策树（depth≤4）
 - 精度优先：XGBoost/LightGBM/CatBoost
 - 大数据量：神经网络（需注意过拟合风险）
- **冷启动策略：**
 - 新店预测可参考相似老店数据（如店A用店B的历史销量）

二、二手车价格预测01:58:00

1. 模型选择 01:58:04

Project: 二手车交易价格预测



• 数据集:

used_car_train_20200313.csv

used_car_testB_20200313.csv

数据来自某交易平台的二手车交易记录

<https://tianchi.aliyun.com/competition/entrance/231784/introduction>

ToDo: 给你一辆车的各个属性(除了price字

段), 预测它的价格

Field	Description
SaleID	交易ID, 唯一编码
name	汽车交易名称, 已脱敏
regDate	汽车注册日期, 例如20160101, 2016年01月01日
model	车型编码, 已脱敏
brand	汽车品牌, 已脱敏
bodyType	车身类型: 豪华轿车: 0, 微型车: 1, 厢型车: 2, 大巴车: 3, 敞篷车: 4, 双门汽车: 5, 商务车: 6, 搅拌车: 7
fuelType	燃油类型: 汽油: 0, 柴油: 1, 液化石油气: 2, 天然气: 3, 混合动力: 4, 其他: 5, 电动: 6
gearbox	变速箱: 手动: 0, 自动: 1
power	发动机功率: 范围 [0, 600]
kilometer	汽车已行驶公里, 单位万km
notRepairedDamage	汽车有尚未修复的损坏: 是: 0, 否: 1
regionCode	地区编码, 已脱敏
seller	销售方: 个体: 0, 非个体: 1
offerType	报价类型: 提供: 0, 请求: 1
creatDate	汽车上线时间, 即开始售卖时间
price	二手车交易价格 (预测目标)
v系列特征	匿名特征, 包含v0-14在内15个匿名特征

- 回归模型推荐: 在传统行业和比赛中常用的回归模型, 可直接应用于风控系统
- 模型特点: 效果稳定可靠, 适合工业级部署应用

2. 超参数调优策略 01:58:38

- 祖传参数法: 提供85分水平的默认参数, 避免过度调参耗时
- 优先级建议: 应将80%时间投入特征工程而非参数调优
- 训练效率: 避免单次训练耗时过长(如4小时), 需检查参数设置合理性

3. 特征工程基础 01:59:35

- 核心定义: 对原始数据进行特征加工的过程
- 数据合并原则: 训练集和测试集必须采用相同的特征计算逻辑
- 合并技巧:
 - 添加source字段区分数据来源(train/test)
 - 保留原始SaleID用于数据追踪
 - 价格字段仅存在于训练集(y值)

4. 业务特征构建 02:00:32

- 时间维度:
 - 车龄计算(creatDate与regDate差值)
 - 注册季节特征提取
- 车辆属性:
 - 品牌-车型组合特征
 - 功率异常值处理(范围[0,600])
- 异常处理: 对无效注册日期采用2016-01-01默认值填充


5. 统计特征构建 02:01:02

- 品牌均价特征: 计算各brand编号对应的价格均值
 - 例: brand=1时, 计算该品牌所有车辆价格平均值
- 价格比特征: 个体价格与品类均值的比值
- 脱敏处理: 通过统计量还原脱敏字段的业务含义

6. 特征编码技术 02:02:15

- 频率编码: 统计各分类编码出现的频次作为新特征
- CatBoost标记: 将分类特征显式声明为category类型
- 组合策略: 与统计特征配合使用增强模型理解

7. 特征工程流程 02:02:43



-
- **数据预处理**
 - 加载并合并训练/测试集
 - 添加数据来源标记
- **特征构建**
 - 时间特征工程
 - 车辆属性工程
 - 统计特征生成
- **特征选择**
 - 删除无效特征 (SaleID/name等)
 - 分类特征类型转换


8. 数据合并实现 02:05:01

- **合并比例**: 15万训练集+5万测试集→20万总数据
- **字段差异**: 测试集缺少price字段 (31→30个特征)
- **ID保存**: 单独存储salesID保证可追溯性

9. 时间特征处理 02:07:20

- **日期解析**: 使用pd.to_datetime转换regDate格式
 - 格式字符串: %Y%m%d对应年月日
- **错误处理**: 设置errors='coerce'自动转换失败返回NaT
- **缺省值填充**: 统一采用2016-01-01作为默认注册日期


10. 特征工程代码结构 02:04:48




-
- **数据持久化**: 使用pickle/joblib保存特征工程结果
- **模型存储**: CatBoost自带模型存储格式(.cbm)
- **文件组织**:
 - 训练/验证集分开存储
 - 分类特征单独保存
 - 测试ID独立存储

三、二手车交易价格预测02:09:04

1. 创建时间特征 02:09:06



1) 车辆年龄计算与异常值修复 02:09:20




- 计算逻辑：车辆年龄=上线时间(creatDate)-注册时间(regDate)，原始数据中这两个时间字段需要先转换为datetime格式

- 单位选择：可以计算天数(vehicle_age_days)或年份(vehicle_age_years=天数/365)

- 异常处理：当年龄为负值时（即上线时间早于注册时间），将异常值强制设为0，因为业务上这种情况不合理

- 缺失值填充：对缺失的日期统一填充为'20160101'作为默认值

2) 时间多尺度处理：年、月、日 02:10:23



- 拆分方法：将完整日期拆分为年、月、日三个独立特征，例如2016-01-01拆分为：

- reg_year=2016
- reg_month=1
- reg_day=1


- 业务意义：不同时间尺度可能对应不同业务规律，如年份反映政策影响，月份反映季节性波动

- 扩展应用：除年月日外，还可提取星期几(weekday)等与业务相关的时间维度

3) 是否为新车特征构造 02:12:25

- **业务逻辑**：将使用年限<1年的车辆标记为新车(is_new_car=1)，否则为0
- **实现方式**：通过布尔条件(data['vehicle_age_years'] < 1)生成二值特征
- **业务价值**：二手车市场中，新车状态是重要定价因素，买家可能特别关注

4) 季节特征构造 02:12:49



- **计算方法**：使用公式 $(x \% 12 + 3) / 3$ 将月份转换为季节(1-4季)
- **业务考量**：虽然季节影响不确定，但保留该特征让模型自行判断重要性
- **特征衍生**：同时计算注册季节(reg_season)和上线季节(creat_season)

5) 业务特征构造思路 02:13:04

- **时间差值法**：可计算与基准日期(如2000-01-01)的天数差，作为连续型特征
- **特征筛选原则**：先广泛构造潜在有用特征，再通过特征重要性进行筛选
- **业务理解**：如特斯拉夏季促销案例说明，特定时间事件可能成为关键特征

6) 每年行驶里程数计算 02:13:45


- **计算公式**：总里程(kilometer)/(车龄年份+0.1)
- **平滑处理**：添加0.1防止除零错误，同时处理车龄接近零的异常情况
- **业务解释**：反映车辆使用强度，是评估车况的重要指标

7) 车龄分档处理 02:14:16

- **分档策略**：将连续车龄划分为业务常用区间：
 - 1年以内
 - 1-3年
 - 3-5年
 - 5-10年
 - 10年以上
- **优势**：离散化处理可以捕捉车龄与价格的非线性关系
- **实现方式**：通过pd.cut()或条件判断实现区间划分

2. 创建车辆特征 02:15:11


1) 二手车交易价格预测项目介绍



- **数据集来源**：某交易平台的二手车交易记录
- **预测目标**：根据车辆属性预测交易价格 (price字段)


- **关键特征:**
 - 发动机功率 (power)
 - 行驶里程 (kilometer)
 - 车身类型 (bodyType)
 - 燃油类型 (fuelType)
 - 变速箱类型 (gearbox)
 - 15个匿名特征 (v0-v14)
- 2) 车辆特征与缺失值处理 02:15:23
 - **缺失值标记:**
 - 创建额外字段标记缺失状态 (如v1_missing=1表示v1有缺失)
 - **原因:** 填充后会丢失原始缺失信息, 需要单独记录
 - **处理逻辑:**
 - 让AI生成初步处理方案, 但需要人工验证和调整
 - AI可能生成过于复杂的逻辑, 需要简化优化
- 3) 缺失值填充与字段标记 02:15:49
 - **填充方法:** 使用中位数填充
 - **标记意义:** 保留原始缺失信息用于后续分析
 - **示例:** 若v1有缺失, 则设置v1_missing=1
- 4) 特征工程与AI生成逻辑 02:16:18
 - **AI辅助建议:**
 - 可先用AI生成特征工程方案
 - 需要人工检查逻辑合理性
 - 复杂逻辑可能需要简化调整
 - **实施要点:** 结合业务理解优化AI生成的方案
- 5) 数值特征转换与交叉特征 02:17:13
 - **数值转换:**
 - 将分类特征 (如model) 转换为数值类型
 - **交叉特征:**
 - 组合品牌 (brand) 和车型 (model) 创建新特征
 - **目的:** 捕捉品牌与车型的交互效应
- 3. 创建统计特征 02:18:26
 - 1) 车龄与异常值处理概述 02:18:27
 - **车龄计算:**
 - 使用当前时间 (假设2025年9月20日) 减去注册日期 (regDate)
 - **异常值影响:** 导致模型不稳定, 预测偏差
 - 2) 异常值的定义与处理方式 02:19:06
 - **定义标准:**
 - 置信区间法: 取5%分位数和95%分位数
 - IQR法: $Q1 - 1.5 \times IQR$ 和 $Q3 + 1.5 \times IQR$
 - **处理方法:**
 - 截断 (clip): 将异常值替换为边界值
 - **调整建议:** 可根据业务调整1.5倍系数
 - 3) 异常值对模型的影响 02:20:35
 - **示例说明:**
 - 银行风控模型中包含马云收入数据
 - 极端值会扭曲特征权重, 影响普通用户预测
 - **解决方案:** 设置收入上限 (如1000万) 处理极端值
 - 4) 车辆数据处理与通用工程 02:21:34

- **重点处理特征:**
 - power (发动机功率)
 - kilometer (行驶里程)
 - v0-v14 (匿名特征)
- **处理步骤:**
 - 缺失值填充
 - 异常值处理
 - 特征转换
- 5) 一点五倍的含义 02:21:55
- **统计意义:** 类似 3σ 原则的宽松标准
- **调整建议:**
 - 增大倍数: 减少异常值捕捉
 - 减小倍数: 增加异常值敏感度
- 6) 统计特征创建的原因 02:22:50
- **核心目的:** 建立品牌与价格的关联关系
- **实现方式:** 通过统计量反映品牌特性
- 7) 品牌与价格的关联属性 02:23:00
- **统计维度:**
 - 平均数
 - 中位数
 - 标准差
 - 频率
- **特征扩展:** 在原数据基础上新增4列统计特征
- 8) 品牌的相对平均价格 02:23:38
- **计算方式:**
 - $\text{brand_price_ratio} = \text{品牌平均价格} / \text{整体平均价格}$
- **分析价值:** 反映品牌价格在整体中的位置
- 9) 统计特征整理与索引找回 02:24:12
- **数据组织:**
 - 保持训练集和测试集索引清晰
 - 确保特征工程一致性
- 4. 编码分类特征 02:24:32
- **编码对象:**
 - 车身类型 (bodyType)
 - 燃油类型 (fuelType)
 - 车型 (model)
 - 品牌 (brand)
- **编码方法:** 频率编码 (统计各类别在数据集中的占比)
- **特征扩展:** 最终得到79维特征 (原始20万条数据)
- 5. 特征选择与数据准备 02:25:45
- 1) 设置模型参数 02:28:43




- 参数配置：
 - learning_rate: 0.03（学习率）
 - depth: 6（树深度）
 - l2_leaf_reg: 3（L2正则化系数）
 - bootstrap_type: 'Bayesian'（贝叶斯自举法）
 - random_seed: 42（随机种子）
 - iterations: 3000（迭代轮数）
 - loss_function: 'MAE'（使用平均绝对误差作为损失函数）
 - eval_metric: 'MAE'（评估指标）
- 参数调优技巧：
 - 学习率建议设置在0.01-0.1之间，初期可稍大加速收敛
 - 迭代次数可设置较高（如2000+），因CatBoost不易过拟合
 - 验证集比例建议保留10%用于模型评估

2) 评估模型性能 02:29:08




- 训练监控：
 - 通过损失曲线观察MAE下降趋势
 - 初始MAE约为4376，快速下降至4342
 - 3000轮训练总耗时约30分钟
- 验证集使用：
 - 类比"考试前的小测试"，用于评估模型能力
 - 创建验证数据池：val_pool = Pool(X_val, cat_features=cat_features)
 - 预测与评估：y_pred = model.predict(val_pool)




-
- **关键特征识别：**
 - v_3 (重要性30.39)
 - v_0 (重要性19.26)
 - v12 (重要性11.01)
 - power (重要性10.17)
- **模型保存与应用：**
 - 保存模型：model.save_model('processed_data/fe_catboost_model.cbm')
 - 生成预测结果：submit_data.to_csv('fe_catboost_submit_result.csv')
 - 实际提交成绩549分 (MAE指标)
- **性能优化建议：**
 - 增加迭代次数可进一步提升精度 (如从1000轮增至3000轮)
 - 学习率调整策略：前期较大加速收敛，后期调小精细优化
 - 特征工程处理 (如缺失值填充、类别编码) 对结果影响显著

6. 思考 02:36:34


1) 误差与模型优化：牛顿下山法的启示 02:36:42



-
- **误差最小化目标：**在误差曲线中，最低点代表预测结果与实际结果的最小误差，是模型优化的最终目标
- **梯度下降原理：**初始随机预测值(y_1')误差较高，类似站在山顶，通过切线方向 (梯度) 以0.05学习率逐步下降
- **学习率调整：**接近目标时需减小学习率，过大学习率会导致在最优解附近震荡 (如0.05学习率产生的稳定收敛)
- 2) **模型性能与学习率调整 02:38:02**
 - **收敛问题：**当损失(loss)接近最小值时，需动态调整学习率避免振荡现象
 - **实践建议：**初始可采用较大学习率快速下降，后期改用小学习率精细调整
- 3) **特征工程：数据预处理与特征创建 02:38:33**



-
- **数据合并：**加载训练集和测试集后合并，便于统一特征处理
- **时间特征：**
 - 车龄计算（当前日期-注册日期）
 - 注册季节（春夏秋冬划分）
- **车辆特征：**
 - 功率特征工程
 - 品牌-车型组合特征
 - 异常值处理（如功率异常车辆）
- **统计特征：**
 - 品牌平均价格
 - 品牌价格比（当前价格/品牌均价）
- **编码处理：**
 - 分类特征频率编码
 - CatBoost专用分类标记
- 4) 模型优化：早停技术的必要性 02:38:50
 - **实现原理：**验证集loss连续N轮（如20轮）未下降时自动停止训练
 - **优势：**
 - 仅需简单判断语句，性能开销极小
 - 允许设置更大迭代次数，模型自主判断最优停止点
 - **实践建议：**常规设置20轮早停阈值，可有效防止过拟合
- 5) 模型保存与加载：持续学习与预测 02:39:50
 - **模型持久化：**训练完成后保存模型文件(.pkl/.h5等格式)
 - **预测流程：**加载模型后直接输入新样本特征即可获得预测结果
 - **注意事项：**预测时无需原始训练数据，仅需保证输入特征与训练时一致
- 6) 缺失值补齐：向量算法的应用 02:40:29
 - **相似度填充：**
 - 将样本视为特征向量
 - 查找K近邻样本
 - 用邻居对应特征值填充缺失
 - **适用场景：**适用于特征间相关性较强的数据集
 - **计算代价：**时间复杂度较高，需权衡精度与效率
- 7) 模型训练与应用：从训练到预测 02:41:30
 - **训练分离：**完成训练的模型成为独立预测单元
 - **预测流程：**新样本只需包含训练时的特征维度即可预测
 - **部署注意：**生产环境需确保特征处理逻辑与训练时完全一致
- 8) 模型评估：测试集与验证集的使用 02:42:09



-
- **测试集特性**：比赛测试集不含真实标签，需提交预测结果由平台评估
- **验证集构建**：从训练集划分10%作为本地验证集
- **评估策略**：提交前先用验证集评估MAE指标，避免盲目提交


9) 模型优化：多模型训练与参数调整 02:44:01

- **集成方法**：
 - CatBoost+XGBoost多模型融合
 - 10折交叉验证
 - Stacking集成
- **优化建议**：优先完成特征工程优化，再考虑复杂模型组合
- **参数搜索**：避免过早网格搜索，先使用默认参数验证特征有效性

10) 特征工程评估与优化 02:44:30

- **评估流程**：
 - 生成特征工程方案
 - 人工复核特征合理性
 - 模型验证特征效果
- **优化重点**：品牌相关统计特征、时间特征、异常值处理


11) 二手车价格预测：特征工程实践与优化 02:45:06



-
- **特征删除**：
 - SaleID (交易ID无意义)
 - name (车型名称冗余)
 - offerType (全为0无异变)
 - seller (99.9%为0)
- **类型转换**：将所有分类特征显式标记为category类型
- **数据校验**：确保分类特征编码正确，数值特征无异常值


7. 特征工程示例 02:45:29

1) 项目文件与代码概览 02:45:31




-
- **项目结构：**包含数据预处理、EDA分析、模型训练（XGBoost/CatBoost）和结果提交等多个模块
- **核心文件：**
 - processed_train.csv: 预处理后的训练数据
 - improved_xgboost_modeling.py: 改进版XGBoost建模脚本
 - feature_engineering_and_catboost.ipynb: 特征工程与CatBoost实现

2) 读取数据与预处理 02:46:00




-
- **数据加载：**
 - 使用pd.read_csv()读取预处理后的CSV文件
 - 打印数据形状信息：print(f"预处理后训练集形状：{processed_train_df.shape}")
- **统计信息：**
 - 计算价格的最小值、最大值、平均值和中位数
 - 使用分位数分析价格分布：quantile([0.01,0.05,0.1,0.25,0.5,0.75,0.9,0.95,0.99])

3) 改进XGBoost建模脚本分析 02:46:34




-
- **主要功能：**
 - 数据准备函数prepare_data_for_xgboost_improved
 - 模型训练参数设置
 - 预测和结果保存流程

- **关键改进：**
 - 更细致的特征工程
 - 优化的模型参数设置
- 4) 特征工程实现：日期特征提取 02:47:32
 - **日期处理：**
 - 将regDate和creatDate转换为datetime类型
 - 提取年、月、日信息：dt.year/dt.month/dt.day
 - **衍生特征：**
 - 计算车龄天数：(creatDate - regDate).dt.days
 - 对测试集进行相同的特征处理
- 5) 特征工程优化建议 02:47:53




- **品牌和车型优化：**
 - 品牌分组（高/中/低流行度）
 - 计算品牌平均价格作为新特征
- **里程数处理：**
 - 分箱处理（very_low到extreme_high）
 - 创建年均行驶里程特征
- **其他优化：**
 - 车龄特征（天数→年数）
 - 功率异常值处理和分组
- 6) 特征工程优化方向及置信度评估 02:48:05
 - **高置信度(80-90)：**
 - 里程数分箱和年均里程特征（90/100）
 - 品牌分组和保值率特征（85/100）
 - **中等置信度(70-80)：**
 - 非线性特征和多项式特征（80/100）
 - 时间序列特征（70/100）
 - **评估依据：**
 - 市场认可度
 - 理论合理性
 - 数据支持程度
- 7) 特征工程优化实现与模型训练 02:51:03




- 实现效果:
 - 特征数量从33个增加到53个 (经过独热编码)
 - 新增品牌流行度分组和平均价格特征
 - 实现里程数分箱和交互特征
- 模型参数:
 - max_depth=7
 - learning_rate=0.85
 - subsample=0.8
 - colsample_bytree=0.8

8) 模型评估与特征重要性分析 02:52:00




- 评估指标:
 - 均方根误差(RMSE)
 - 平均绝对误差(MAE)
 - R2分数
- 重要特征:
 - 品牌相关特征 (v_33等)
 - 功率(power)
 - 车龄分段(age_segment)
 - 里程数(kilometer)

9) 优化版本模型总结与提交 02:56:23



-
- **预测结果统计:**
 - 最小值: 0.33
 - 最大值: 86180.20
 - 平均值: 5528.84
 - 中位数: 2928.72
- **提交文件:**
 - xgboost_optimized_result.csv
 - fe_catboost_submit_result.csv

四、内容总结02:59:48



-
- 1. 比赛任务说明
 - **比赛目标:** 阿里云天池AI大赛的二手车价格预测任务，要求编写AI算法将预测分数优化到<500分
 - **数据来源:**
 - 训练集: used_car_train_20200313.csv
 - 测试集: used_car_test_20200421.csv
 - **比赛链接:** <https://tianchi.aliyun.com/competition/entrance/231784/information>
- 2. 模型优化策略
 - **模型选择:** 需要选择适合回归预测任务的机器学习模型
 - **特征工程:**
 - 时间特征处理
 - 车辆属性特征提取
 - 统计特征构建
 - 分类特征编码
 - 异常值检测与处理
- 3. 优化经验分享
 - **迭代过程:**
 - 初始分数800多分
 - 通过特征工程优化到550分以内

- 优化建议:
 - 发掘更多有价值的特征
 - 采用更复杂的特征工程方法
 - 持续迭代优化模型
- 最终目标: 将预测分数稳定控制在500分以内

五、知识小结

分类维度	核心内容	关键知识点/技术要点	应用案例/实践建议
课程类型	AI算法应用课程	特征工程/模型选择/调参技巧	二手车价格预测实战
核心主题	金融科技算法	评分卡模型/客户流失预警/千人十面策略	银行风控系统/保险续保预测
关键技术	特征工程	特征决定上限/多尺度时间特征/统计特征构造	车龄分段/品牌价格比/异常值处理
模型对比	算法选型	逻辑回归(可解释性) vs CatBoost(防过拟合)	金融场景优先选择可解释模型
行业应用	制造业缺陷检测	螺栓扭矩曲线分析/强光反射检测	上汽大众质检系统/YOLO网络应用
数据策略	验证集构建	10%数据分割/早停技术(20轮阈值)	本地验证避免提交次数浪费
性能优化	超参设置	学习率0.05/迭代3000轮/中位数填充	优先特征工程而非网格搜索
工具链	AI编程工具	五彩/Cursor代码生成/VSCode调试	避免直接使用大模型决策
竞赛技巧	天池比赛	MAE指标优化/特征重要性分析	从800分→550分优化路径
前沿趋势	AI Agent架构	大模型交互层+小模型决策层	金融场景的幻觉控制方案